Asesor de tecnología de IA para emprendedores y pymes

Borrador de las secciones 0 y 1 del informe TAAI2. Cifras tomadas de `Anexo_B_FINAL.xlsx` y de las evaluaciones del proyecto. La consultora es ficticia y sus cifras son supuestos que el grupo debe justificar.

0. Resumen ejecutivo

La solución. Un asesor que recibe la descripción de una idea o de un negocio y recomienda la tecnología de IA **más simple que alcanza**, con su costo y el volumen en que se justificaría algo más caro. Combina un modelo de lenguaje con RAG sobre un corpus de reglas, un verificador que bloquea respuestas sin respaldo y un humano que toma la decisión final.

Veredicto propuesto: viable con condiciones.

Presupuesto (50.000 consultas al mes, alternativa recomendada: API comercial + RAG + verificador). TCO a 12 meses: 35.622 USD. TCO a 36 meses: 96.866 USD, con VAN positivo y punto de equilibrio en el mes 1. Las alternativas cuestan más: modelo propio 217.434 USD y híbrido 158.447 USD a 36 meses. El modelo propio solo se paga sobre unos 92 millones de consultas al mes. El costo lo domina el personal, no los tokens: variar el volumen de consultas en 30 % mueve el TCO en menos de 40 USD, mientras que variar el personal en 30 % lo mueve en 54.000 USD.

Evidencia de que funciona. En 32 preguntas con 3 repeticiones, el LLM solo recomienda algo sobredimensionado en 11,5 % de los casos. Con RAG y verificador baja a 0 %, y las alucinaciones caen a 0 %, con una latencia de 1,2 s y unos 0,00013 USD por consulta. En 31 preguntas nuevas (1 repetición) el sistema híbrido acierta 80,6 %, pero la sobredimensión sube a 7,4 %.

Los tres riesgos mayores (propuestos).

1. **Dependencia de un proveedor de API.** Cambios de precio o de condiciones afectan al servicio.
2. **Recomendaciones erróneas o abstenciones.** El verificador elimina las alucinaciones, pero el sistema se abstiene entre 13 % y 22 % de las veces.
3. **Validez de la evaluación.** Las reglas y las etiquetas de referencia las definió el propio grupo y aún no las valida un experto externo.

1. La solución y el problema que resuelve

1.1 La organización

Camino Digital SpA (ficticia) es una consultora que asesora a emprendedores y pymes chilenas sin equipo técnico en qué automatizar. Supuestos de contexto, a validar: 25 consultores y unos 10.000 emprendedores activos, que hacen en promedio 5 consultas al mes (50.000 consultas mensuales).

1.2 Usuarios

- **Emprendedores y pymes**: dueños de negocios que no saben si les basta una planilla, un bot de reglas o una solución con IA generativa.

- **Consultores de la firma**: reciben un prediagnóstico ya armado y concentran su tiempo en los casos complejos.

1.3 Proceso actual y dolor medible

Hoy un consultor atiende cada consulta inicial a mano. Supuesto de costo: 3 minutos de un ejecutivo de primer nivel, a unos 8 USD por hora, equivale a **0,40 USD por caso**. Si el asesor automatiza el 50 % de las 50.000 consultas, el ahorro es de **10.000 USD al mes**.

Hay un segundo costo, más difícil de medir: el cliente que recibe una propuesta sobredimensionada y paga por una solución que no necesitaba. La evaluación del proyecto lo cuantifica en el asesor: un LLM sin respaldo recomienda algo más complejo de lo necesario en 11,5 % de los casos. El costo en dinero para el cliente es un supuesto a validar con los casos reales de la consultora.

1.4 La solución

El asesor sigue una escalera de decisión, de lo más simple a lo más caro, y elige el primer peldaño que resuelve el problema y se paga solo:

Nivel	Solución	Cuándo basta
0	Sin IA: planilla, FAQ, agenda	Pocas consultas o proceso poco estable
1	Bot de reglas o árbol de decisión	Pocas preguntas fijas con respuestas fijas
2	IA generativa con RAG sobre sus documentos	Preguntas abiertas cuyas respuestas están en documentos
3	ML clásico (Random Forest, Boosting)	Predicción con datos tabulares y un historial etiquetado
4	RAG con reglas duras y verificador	Hay normativa o un error es costoso
5	Agente con herramientas y humano	El sistema debe ejecutar acciones
6	Modelo propio (SLM)	Volumen muy alto o datos que no pueden salir de la empresa

Para cada recomendación entrega el costo estimado, el volumen en que se justificaría un nivel superior y alertas de sobreventa. Un verificador comprueba que cada afirmación tenga respaldo en el corpus y se abstiene cuando no lo tiene.

1.5 Alcance y qué queda fuera

Dentro: orientar la elección de tecnología para emprendedores y pymes, con costos y puntos de equilibrio.

Fuera: implementar la solución elegida, recomendar proveedores específicos, proyectos de ML a gran escala y asesoría legal o tributaria.

1.6 Cumplimiento de las condiciones del enunciado

1. **Modelo fundacional adaptado:** un LLM con RAG sobre el corpus de reglas del asesor.
2. **Decisiones con algún grado de autonomía:** el sistema propone la tecnología, calcula costos y avisa de la sobreventa. La decisión final es de la persona.
3. **Dueño, usuarios y problema con costo medible:** Camino Digital SpA, emprendedores y pymes, y el costo de atención manual más el de las propuestas sobredimensionadas.

1.7 Supuestos a validar antes de entregar

- Volumen de 50.000 consultas al mes y 25 consultores: cifras ficticias, deben quedar en el Anexo B.
- Costo de 0,40 USD por caso y 50 % de automatización: sin fuente verificada.
- Personal, CAPEX y tasa de descuento: sin fuente verificada, y son lo que más pesa en el presupuesto.
- Etiquetas de la evaluación: definidas por el grupo; declarar si alguien externo las revisó.

2. Modelos fundacionales y adaptación (Sesión 1)

2.1 Qué modelo necesita cada componente

Componente	Modelo	Por qué
Redacción de la recomendación	LLM causal por API (OpenAI)	Combina las reglas recuperadas y la descripción libre del negocio en una respuesta justificada
Alternativa de despliegue propio	SLM Qwen2.5-1.5B local	Se mide como opción de menor costo y mayor control de datos; resultó peor
Recuperación de reglas	Búsqueda sobre el corpus de 21 reglas, top-5	Entrega al modelo solo las reglas relevantes
Piso simbólico	Motor de reglas (árbol de decisión) con extractor de datos	Referencia sin generación libre

El asesor no usa modelos multimodales ni ML clásico: no recibe imágenes ni tiene datos tabulares propios. Sí los recomienda a sus usuarios cuando corresponde (nivel 3 de la escalera).

PENDIENTE: confirmar si la recuperación es léxica (BM25) o por embeddings (ver `retrieve` en `copilot/evaluator.py`) y escribirlo aquí. Si es léxica, comentar que una representación distribuida (embeddings) captaría mejor los sinónimos, a cambio de más costo y menos trazabilidad. Esto cubre el punto de representación distribuida contra simbólica que pide el enunciado.

2.2 Técnica de adaptación

- **RAG (elegida).** Las reglas del asesor son 21 y cambian con el tiempo; editarlas es más barato y trazable que reentrenar. Cada respuesta cita la regla que usó.

- **Aprendizaje en contexto.** El prompt fija el formato de salida (RECOMENDACION o COMPONENTES) y la abstención cuando no hay información.
- **Ajuste fino y destilación (descartados por ahora).** Con un corpus tan pequeño no hay datos para entrenar, y el CAPEX supuesto sube de 5.000 a 15.000 USD. El SLM local con RAG alcanzó 68,8 % de respuestas correctas, contra 81,2 % del modelo por API.

2.3 Límites de contexto y costo por consulta

El sistema híbrido usa en promedio unos 613 tokens de entrada, muy por debajo de cualquier límite de contexto. **Observación honesta:** con solo 21 reglas el corpus completo cabría en el prompt y el RAG no sería estrictamente necesario; se justifica porque el corpus crecerá.

El costo medido del sistema híbrido es de **0,00013 USD por consulta**: unos 6,5 USD al mes con 50.000 consultas.

PENDIENTE: `Anexo_B_FINAL.xlsx` usa 175 tokens de entrada y 17 de salida, medidos en el benchmark de la tarea, mientras que el asesor usa unos 520 a 610 de entrada. Rehacer el cálculo con los tokens del asesor (`python run_eval_asesor.py` regenera el Excel de `eval_asesor/`). El efecto en el TCO es pequeño, pero las cifras deben ser consistentes.

3. Autonomía, arquitectura agentic y gobernanza (Sesión 2)

3.1 Componentes

Componente	Función
Interfaz	Entrada de la idea o del perfil del negocio (web o línea de comandos)
Orquestador	Encadena las etapas: clasificar, recuperar reglas, redactar, verificar, aprobar
Memoria	Corpus de 21 reglas y resultados de cada corrida
Herramientas	Calculadora de presupuesto (TCO, VAN, equilibrio) y motor de reglas
Verificador	Comprueba formato, citas y cifras; reintenta o se abstiene
Humano	Un consultor de Camino Digital revisa los casos sensibles

Es un sistema de un solo agente con herramientas y un verificador independiente. No es multiagente: no hay negociación ni dinámica entre agentes, porque el problema es una consulta con una respuesta, y agregar agentes sumaría costo y errores sin beneficio.

3.2 Nivel de autonomía por tipo de acción

Acción	Autonomía	Humano en el circuito
Recomendar una tecnología	El sistema propone	La persona decide; la acción es reversible
Calcular costos y equilibrio	Automática	No

Acción	Autonomía	Humano en el circuito
Abstenerse si no hay respaldo	Automática	Deriva a un consultor
Casos regulados o de alto costo de error	El sistema prepara	Un consultor revisa antes de entregar
Contratar o implementar	No actúa	Fuera de alcance

3.3 Trazabilidad, auditoría y gobernanza

Cada respuesta cita las reglas usadas con el formato [n]. Cada corrida guarda la pregunta, las reglas recuperadas, la respuesta, el resultado de la verificación y los reintentos en un JSON auditable. El dueño del corpus es la consultora, que revisa las reglas cada trimestre y registra los cambios.

PENDIENTE: definir los nombres de los roles (dueño del corpus, responsable de la revisión) y la frecuencia de auditoría que la consultora ficticia adoptaría.

3.4 Confiabilidad de la cadena

Si un flujo tiene n pasos con precisión pi, la precisión del flujo es el producto de todas. Un humano que detecta una fracción c de los errores de un paso lo mejora a pi + (1 − pi) · c.

Escenario (ejemplo)	Precisión del flujo
4 pasos de 0,95; 0,90; 0,92; 0,97	0,787
Mismo flujo, con humano que detecta 80 % de errores en el paso 3	0,841

Las cifras son un ejemplo ilustrativo de `python -m copilot.engine_taai2 reliability`.

PENDIENTE: reemplazar el ejemplo por precisiones medidas por paso, que ya existen en parte: recuperación (recall de la regla correcta en el top-5: 1,0 en la evaluación interna), formato válido, citas válidas y etiqueta correcta (77,1 % en el híbrido). Calcularlas desde `eval_asesor/resultados_asesor.json` y multiplicarlas.

4. Razonamiento simbólico y verificación (Sesión 3)

4.1 Reglas duras

El verificador aplica cuatro tipos de restricción sobre lo que genera el LLM:

1. **Formato:** la primera línea debe ser RECOMENDACION con una etiqueta válida, o COMPONENTES con una lista de componentes válidos.
2. **Citas:** cada [n] debe corresponder a una regla recuperada.
3. **Cifras:** todo número de la respuesta debe aparecer en las reglas o en la pregunta del usuario. Un número inventado se rechaza.
4. **Abstención:** si no hay respaldo, la única salida válida es NO_HAY_INFORMACION.

Además, el verificador de políticas exige latencia máxima de 5 segundos, un presupuesto definido, un humano ante acciones irreversibles y anonimización de datos personales.

4.2 Estructura de conocimiento

Las tecnologías forman un orden de complejidad y costo: sin IA < reglas < ML tabular o API con RAG < SLM propio < agente. El asesor usa ese orden para medir la sobredimensión (recomendar un nivel más alto que el necesario) y la subdimensión.

PENDIENTE: no hay una ontología ni un grafo de conocimiento formal; si el informe los menciona, justificar por qué no se justifican con 21 reglas, o dibujar el orden de la escalera como un grafo de dependencias.

4.3 Efecto sobre las alucinaciones y costo de mantenimiento

En la evaluación interna (32 preguntas, 3 repeticiones), el RAG sin verificador alucina en 17,7 % de los casos y el híbrido con verificador en 0 %. El precio es la abstención: 21,9 % en el híbrido contra 15,6 % en el RAG solo.

Mantener el sistema exige redactar y probar cada regla nueva. Un falso positivo real que se corrigió: el verificador marcaba como inventadas las cifras que el usuario mismo había dado en su pregunta; ahora las acepta.

5. Planificación (Sesión 4)

5.1 Qué decisión es un problema de planificación

El asesor no planifica acciones sobre el mundo, pero sí secuencia las etapas de cada consulta. Es un problema de planificación clásico: estado inicial (caso recibido), meta (respuesta entregada y aprobada) y acciones con precondiciones y efectos.

Acción	Precondición	Efecto
clasificar	caso	clasificado
recuperar_reglas	clasificado	reglas
redactar	reglas	borrador
verificar	borrador	verificado
aprobar_humano	verificado	aprobado
ejecutar	verificado y aprobado	ejecutado

Una búsqueda en anchura (STRIPS) encuentra la secuencia correcta, y la restricción de que ejecutar requiere aprobación humana es lo que impide saltarse el control.

5.2 Replanificación

Cuando la verificación falla, el sistema replanifica: primero repara citas, luego reintenta una vez con retroalimentación y, si falla, se abstiene. En el híbrido, el 5,2 % de las respuestas se reparó y el 16,7 % requirió reintento.

5.3 Reparto entre planificador, LLM y verificador

El planificador decide el orden de las etapas, el LLM redacta, y el verificador decide si la salida avanza.

PENDIENTE: el enunciado pide comparar contra un LLM que planifica solo. No se midió. Para hacerlo: pedirle a un LLM que ejecute el flujo completo en un solo prompt y comparar tasa de respuestas correctas y de pasos omitidos contra el flujo con planificador. Si no hay tiempo, declararlo como trabajo futuro.

6. Optimización y metaheurísticas (Sesión 5)

6.1 Qué decisión es un problema de optimización

El cliente de la consultora suele tener varias automatizaciones posibles y un presupuesto limitado. Elegir cuáles abordar es un problema de optimización:

- **Variables:** xi = 1 si se implementa la automatización i, 0 si no.
- **Función objetivo:** maximizar el ahorro mensual neto, es decir, la suma de (ahorro i − costo i) · xi.
- **Restricciones:** presupuesto total, personal disponible y dependencias entre automatizaciones.
- **Tamaño:** con n candidatas hay 2^n combinaciones; con n = 10 son 1.024. Es una variante del problema de la mochila, que es NP-duro en general, pero con n pequeño se resuelve exacto por enumeración.

6.2 Método propuesto

Enumeración exacta para n pequeño y recocido simulado si n crece. La IA generativa entra a formular el problema desde la descripción del negocio y a explicar la solución, pero no a resolverla: aquí el método tradicional gana porque es exacto, barato y verificable.

En el proyecto hay un optimizador de reparto de tareas: el recocido simulado alcanza 12 horas de makespan, igual al óptimo exacto, y supera al método voraz (13 horas). Se usa como evidencia de la técnica.

PENDIENTE: el proyecto no implementa la selección de portafolio. Para implementarla, escribir una función de unas 10 líneas que recorra todos los subconjuntos y devuelva el de mayor ahorro que cumple el presupuesto, y mostrar un ejemplo con 5 a 8 automatizaciones. Si no hay tiempo, presentar el modelo matemático y justificar.

6.3 Presupuesto de cómputo

El cómputo de esta parte es despreciable: la enumeración de 1.024 combinaciones corre en milisegundos y no genera costo apreciable en la nube.

7. Despliegue y operación (Sesión 5 · demo Finbot y Hugging Face Hub)

7.1 Estado actual

El asesor corre localmente: una interfaz web (`python -m copilot web`), la línea de comandos y un flujo de demostración (`run_pipeline.py`) que compara OpenAI contra un modelo local de Hugging Face. No hay despliegue en la nube ni Dockerfile.

7.2 Diseño de despliegue propuesto

Elemento	Configuración propuesta	Justificación
Servicio	Cloud Run (contenedor): 1 CPU, 512 MiB a 1 GiB, mínimo 0 y máximo 5 instancias, concurrencia inicial de 40	El modelo se consume por API, así que no necesita GPU; escala a cero para no pagar en horas sin tráfico
Secretos	Secret Manager para la clave de OpenAI	La clave no viaja en la imagen ni en archivos
Imágenes	Artifact Registry, con una etiqueta por versión	Permite volver a una versión anterior
CI/CD	GitHub Actions: pruebas (56), construcción y despliegue	Una prueba que falla bloquea el despliegue
Corpus y modelos	Repositorio de Git y Hugging Face Hub, con etiquetas de versión	El corpus de reglas se versiona como código
Observabilidad	Cloud Logging y métricas de latencia p95, abstención, reintentos y costo por consulta	Son las métricas que decide el piloto
Rollback	Redirigir el 100 % del tráfico a la revisión anterior de Cloud Run	Es inmediato y no requiere recompilar

Latencia objetivo: p95 de 3 segundos o menos. El híbrido por API mide 2,4 s; el modelo local en GPU mide 14 s y no sirve para atención en línea, solo como contingencia o proceso por lotes.

Sincronización de estado: el servicio no guarda estado; el corpus está versionado y los registros se escriben en almacenamiento externo.

PENDIENTE: esto es un diseño, no un despliegue. Para que cuente como evidencia (secciones 7 y 11): crear un Dockerfile, ejecutar `gcloud run deploy` con un servicio mínimo, y adjuntar una captura de la URL funcionando y de la revisión. Verificar cada valor de configuración en la documentación oficial de Cloud Run y anotar la fecha de consulta.

8. Presupuesto (Sesión 6 · Economía de la IA, con S1 y S5)

8.1 Alternativas comparadas (50.000 consultas al mes)

Alternativa	CAPEX (USD)	TCO 12 meses	TCO 36 meses	VAN 36 meses	Equilibrio
API comercial + RAG + verificador	5.000	35.622	**96.866**	227.282	mes 1
Híbrido (80 % modelo propio, 20 % API)	10.000	59.482	158.447	173.266	mes 2
Modelo propio (SLM en infraestructura dedicada)	15.000	82.478	217.434	121.498	mes 4

El punto de equilibrio entre la API y el modelo propio está en unos **92 millones de consultas al mes**, casi 2.000 veces el volumen supuesto. Por eso se recomienda la API.

8.2 Sensibilidad (TCO a 36 meses, variaciones de 30 %)

Alternativa	Variable	Oscilación del TCO (USD)
API	Costo de personal	54.000
API	CAPEX	3.000
API	Consultas al mes	39
Modelo propio	Costo de personal	118.800
Modelo propio	CAPEX	9.000
Modelo propio	Costo por hora de GPU	500

La conclusión es que **el costo lo domina el personal, no los tokens**. Si el precio de los modelos baja 10 veces, el TCO de la API a 36 meses pasa de 96.866 a 96.807 USD, un cambio de 0,06 %.

8.3 Supuestos principales

Variable	Valor	Fuente
Consultas al mes	50.000	Supuesto del grupo (consultora ficticia)
Precio de la API	0,15 USD por millón de tokens de entrada y 0,60 de salida	Página oficial de precios de OpenAI, consultada el 2026-11-01
Tokens por consulta	175 de entrada y 17 de salida	Medidos en el benchmark de la tarea (ver pendiente)
Costo por hora de GPU	1,20 USD	Supuesto sin fuente

Variable	Valor	Fuente
Personal (API, híbrido, modelo propio)	2.500, 4.000 y 5.500 USD al mes	Supuesto sin fuente
Costo manual por caso	0,40 USD	Supuesto: 3 minutos de un ejecutivo a 8 USD por hora
Tasa de automatización	50 %	Supuesto sin fuente
Tasa de descuento	10 % anual	Supuesto sin fuente

PENDIENTES del presupuesto, en orden de importancia:

1. **Justificar el personal**, que es lo que más pesa. El enunciado pide roles, dedicación y costo mensual: por ejemplo, 0,5 de un ingeniero de IA a 5.000 USD al mes de costo total, citando una fuente de remuneraciones con fecha.
2. **Corregir las horas de GPU del modelo propio.** El Excel usa 19,3 horas al mes (unos 23 USD), que es solo el tiempo de cómputo medido. Un servicio disponible todo el mes serían unas 730 horas, es decir, unos 876 USD al mes, lo que sumaría unos 30.700 USD al TCO a 36 meses. No cambia la recomendación, porque el modelo propio ya es el más caro.
3. **Rehacer los tokens** con los valores del asesor (ver sección 2.3).
4. **Agregar las líneas que faltan** y que el enunciado menciona: datos y anotación, licencias y cambio organizacional (capacitación de los consultores).
5. **Sensibilidad del VAN**, no solo del TCO: el beneficio depende del costo por caso y de la tasa de automatización. `python -m copilot.engine_taai2 budget` la imprime.
6. **Una figura propia** con el TCO de las tres alternativas y otra con la sensibilidad (gráfico tipo tornado).

9. Factibilidad y riesgos (Sesión 2 · gobernanza, Sesión 6 · riesgos)

9.1 Las cuatro dimensiones

Dimensión	Evaluación	Evidencia
Técnica	Viable con condiciones	77 % a 81 % de respuestas correctas, 0 % de alucinaciones con verificador, p95 de 2,4 s; la sobredimensión llega a 7,4 % en preguntas nuevas
Económica	Viable	TCO a 36 meses de 96.866 USD con VAN positivo; depende de los supuestos de beneficio
Operacional	Viable con condiciones	La abstención (13 % a 22 %) deriva casos a consultores: con 50.000 consultas, un 20 % serían 10.000 casos al mes
Legal y regulatoria	Por validar	Ver abajo

Legal. El asesor procesa descripciones de negocios, no datos personales, y debe advertir al usuario que no los ingrese. Hay que revisar la Ley 19.628 de datos personales y la nueva ley de protección de datos de Chile, y como referencia el Reglamento de IA de la Unión Europea, donde un asistente conversacional tiene obligaciones de transparencia (informar que se interactúa con una IA). También hay que revisar las condiciones del proveedor de la API sobre retención de datos.

PENDIENTE: verificar en las fuentes oficiales qué leyes están vigentes hoy, desde qué fecha y qué obligaciones imponen; citarlas con fecha de consulta. Idealmente, revisión por una persona del área legal. Medir la tasa real de abstención en el piloto.

9.2 Matriz de riesgos

Probabilidad e impacto en escala de 1 a 5; prioridad = probabilidad por impacto.

Riesgo	Prob.	Impacto	Prioridad	Mitigación	Dueño
Dependencia tecnológica y concentración en un proveedor de API	4	4	16	Capa de abstracción para cambiar de proveedor; modelo local como respaldo (68,8 % de respuestas correctas, medido)	Arquitecto de soluciones
Validez de la evaluación: reglas y etiquetas definidas por el propio grupo	4	4	16	Validación externa de las etiquetas por dos personas y un piloto con casos reales	Responsable de calidad
Recomendaciones erróneas o abstención excesiva	3	5	15	Verificador, abstención con derivación a un consultor y revisión humana de casos sensibles	Líder de IA
Seguridad: fuga de claves o inyección de instrucciones	2	5	10	Secret Manager, mínimo privilegio, nunca incluir el archivo de claves en un zip; regenerar las claves expuestas	Responsable de seguridad
Adopción por usuarios y consultores	3	3	9	Piloto con clientes seleccionados y capacitación	Gerencia comercial
Incumplimiento de datos personales o normativa	2	4	8	Advertencia al usuario, minimización de datos, revisión legal	Asesor legal

Riesgo	Prob.	Impacto	Prioridad	Mitigación	Dueño
Costos variables de tokens	2	2	4	Cuotas y alertas de gasto; el costo medido es de unos 6,5 USD al mes	Finanzas

Un incidente real del proyecto: el archivo de claves viajó dentro de varios zips. Se recomendó regenerarlas.

PENDIENTE: ajustar probabilidades e impactos con el grupo, y confirmar si las claves ya se regeneraron.

10. Estrategia y modelo de negocio (Sesión 6)

10.1 Mercado y tendencias

Tres tendencias afectan a la solución: los agentes que ejecutan acciones, los modelos multimodales y la baja sostenida del precio de los modelos. La tercera favorece al asesor, porque abarata la API frente al modelo propio.

PENDIENTE: citar de dos a tres fuentes con fecha (páginas de precios históricos de proveedores, informes del sector) que respalden cada tendencia. No afirmar cifras de mercado sin fuente.

10.2 Modelo de negocio

1. **Ahorro interno:** el asesor atiende las consultas iniciales; supuesto de 10.000 USD al mes.
2. **AI-as-a-Service:** suscripción a pymes. El costo operativo de la API equivale a unos 0,26 USD por cliente activo al mes (2.552 USD mensuales entre 10.000 clientes).
3. **Generación de clientes:** el asesor deriva a los consultores los casos que sí requieren un proyecto.

PENDIENTE: definir el precio de la suscripción y calcular el margen con el Excel.

10.3 Conflicto de interés

Una consultora gana con proyectos grandes, y un asesor que recomienda lo más simple puede reducir esos ingresos. Se mitiga con un modelo basado en suscripción y honorarios fijos, y con auditoría periódica de las recomendaciones. El diferenciador es justamente la neutralidad, que debe poder comprobarse.

10.4 Posición frente a big tech y startups

Los grandes proveedores ofrecen asistentes genéricos que no conocen la realidad local ni comparan opciones con su costo; las startups ofrecen bots por rubro. La ventaja del asesor es el corpus de reglas con costos, la verificación de cada afirmación y la neutralidad.

Tokens y activos descentralizados: no aplica. El asesor no necesita incentivos ni pagos descentralizados, y sumarlos agregaría complejidad regulatoria sin beneficio.

10.5 Dos escenarios

- **Si el costo de los modelos baja 10 veces:** el TCO casi no cambia (menos de 0,1 %), porque el costo es el personal. La ventaja competitiva no depende del precio del modelo, y la baja refuerza la elección de API frente al modelo propio.
- **Si el proveedor principal cambia sus condiciones:** la capa de abstracción permite migrar; el modelo local es el respaldo, con peor calidad (68,8 % contra 81,2 %).

11. Plan de evaluación (transversal, Sesiones 1 a 5)

11.1 Métricas por componente y criterios del piloto

Componente	Métrica	Resultado actual (híbrido)	Umbral del piloto
Recuperación	Recall de la regla correcta en el top-5	1,0 (interna); no medido en la externa	0,9 o más
Generación	Respuestas correctas	77,1 % (interna), 80,6 % (externa)	80 % o más en casos reales
Generación	Sobredimensión	0 % (interna), 7,4 % (externa)	5 % o menos
Verificador	Alucinaciones	0 % en ambas	2 % o menos
Verificador	Abstención	21,9 % (interna), 12,9 % (externa)	15 % o menos
Sistema	Latencia p95	2,4 s	3 s o menos
Sistema	Costo por consulta	0,00013 USD	0,0003 USD o menos

11.2 Resultados medidos

Conjunto interno: 32 preguntas, 3 repeticiones (96 respuestas por configuración).

Configuración	Correctas	Sobredim.	Subdim.	Alucinación	Abstención	Latencia p50
LLM solo	50,0 %	11,5 %	34,5 %	6,2 %	0 %	1,2 s
RAG con OpenAI	81,2 %	0 %	13,8 %	17,7 %	15,6 %	1,1 s
RAG con Qwen local	68,8 %	6,9 %	20,7 %	31,2 %	0 %	6,4 s
Híbrido (RAG + verificador)	77,1 %	0 %	11,5 %	**0 %**	21,9 %	1,2 s
Híbrido con Qwen local	53,1 %	6,9 %	20,7 %	0 %	15,6 %	7,4 s

Conjunto externo: 31 preguntas nuevas, 1 repetición.

Configuración	Correctas	Sobredim.	Subdim.	Alucinación	Abstención
LLM solo	64,5 %	7,4 %	18,5 %	3,2 %	0 %
RAG con OpenAI	80,6 %	0 %	18,5 %	0 %	16,1 %
Híbrido	80,6 %	7,4 %	14,8 %	0 %	12,9 %
Motor de reglas	35,5 %	11,1 %	44,4 %	0 %	3,2 %

Lectura. El resultado más sólido es que el verificador elimina las alucinaciones. La diferencia de exactitud entre el RAG y el híbrido (81 % contra 77 %) no es significativa con 32 preguntas. El motor de reglas es un piso simbólico: no alucina, pero acierta poco.

11.3 Cómo se juzga

El conjunto de preguntas es fijo y las respuestas se comparan automáticamente con una etiqueta de referencia (no se usa un LLM como juez). Se evalúan dos conjuntos: uno interno y uno nuevo, pensado para medir si el sistema generaliza.

11.4 Limitaciones declaradas

- Las reglas del corpus y las etiquetas de referencia las definió el grupo. Las preguntas nuevas las redactó el asistente de IA usado en el proyecto, y aún no las revisa una persona externa.
- El conjunto externo se ejecutó con una sola repetición y sin los modelos locales.
- Con 32 y 31 preguntas, una pregunta pesa unos 3 puntos porcentuales.
- Se hicieron ajustes entre corridas (el parser de preguntas compuestas, el verificador y el prompt), así que parte de la mejora viene de haber visto las preguntas internas.

11.5 Piloto

Diseño propuesto: 4 a 6 semanas con 200 consultas reales de 5 a 10 clientes, donde un consultor etiqueta la tecnología que él recomendaría sin ver la respuesta del asesor.

- **Criterio de éxito:** se cumplen los umbrales de la tabla 11.1.
- **Criterio de parada:** cualquier alucinación con consecuencia económica para un cliente, abstención sobre 25 % o sobredimensión sobre 10 %.
- **Qué cambiaría la recomendación:** si la sobredimensión pasa de 10 % o las correctas bajan de 70 %, se pivota a un bot de reglas con derivación a un consultor. Si la abstención pasa de 25 %, se amplía el corpus antes de escalar.

PENDIENTES de la evaluación:

1. Que dos personas ajenas al grupo etiqueten las 31 preguntas nuevas sin ver las etiquetas del grupo, y descartar o corregir las que no coincidan. Declarar quiénes fueron.
2. Repetir el conjunto externo con 3 repeticiones: `python run_eval_asesor.py --repeats 3 --preguntas eval_asesor/preguntas_externas.json --salida eval_asesor/externas`.
3. Incluir las configuraciones con modelo local en el conjunto externo (omitir `--skip-local`).

4. Una figura propia con las métricas por configuración (barras agrupadas).

12. Recomendación

Ir, por etapas y con condiciones.

12.1 Condiciones

1. Validar externamente las etiquetas y repetir la evaluación con 3 repeticiones.
2. Corregir el presupuesto: tokens del asesor, horas de GPU del modelo propio y líneas faltantes.
3. Justificar con una fuente el costo de personal, que es la variable que más pesa.
4. Confirmar con revisión legal los requisitos de datos personales.
5. Regenerar las claves expuestas y no compartir el archivo de claves.

12.2 Hitos de inversión

Etapa	Qué se hace	Costo estimado (supuesto)	Criterio para avanzar
1. Piloto	Despliegue mínimo en la nube y 200 consultas reales	CAPEX de 5.000 USD más 3 meses de operación (2.552 USD al mes): unos 12.700 USD	Se cumplen los umbrales de 11.1
2. Lanzamiento	Abrir el servicio a los clientes de la consultora y medir el beneficio real	Operación mensual de unos 2.552 USD	Ahorro medido por sobre el costo mensual
3. Revisión de modelo propio	Evaluar un modelo propio solo si el volumen o los requisitos de privacidad lo justifican	Desde 15.000 USD de CAPEX	Volumen cercano al punto de equilibrio o exigencia de datos locales

12.3 Decisión del comité

Si fuéramos el comité ejecutivo, **aprobaríamos solo la etapa 1**, con el presupuesto del piloto y sus criterios de parada. **No aprobaríamos un modelo propio**: con el volumen supuesto, el equilibrio está unos 92 millones de consultas al mes por encima. Revisaríamos la decisión con los resultados del piloto.

Anexo A. Tabla de trazabilidad del syllabus

PENDIENTE: completar la columna de página al exportar el PDF final. `python -m copilot.engine_taai2 traceability` genera la estructura base.

Sesión	Contenido	Sección	Página	Cómo se aplica o por qué no aplica
S1	Tipos de modelo: LLM, MLM, multimodal, SLM, de dominio	2.1	[pág.]	LLM por API y SLM local; multimodal y ML tabular no se usan en el asesor y se justifica
S1	Adaptación: ICL, RAG, LoRA, destilación	2.2	[pág.]	RAG e ICL elegidos; ajuste fino y destilación descartados
S1	Contexto, tokens y costo por consulta	2.3 y 8	[pág.]	613 tokens de entrada; 0,00013 USD por consulta
S1	Representación distribuida y simbólica	2.1	[pág.]	Pendiente: confirmar el tipo de recuperación
S2	Arquitectura agentic	3.1	[pág.]	Un agente con herramientas y verificador
S2	Niveles de autonomía y humano en el circuito	3.2	[pág.]	Tabla por tipo de acción
S2	Confiabilidad de la cadena	3.4	[pág.]	Producto de precisiones por paso; falta medirlas
S2	Sistemas complejos y dinámica entre agentes	3.1	[pág.]	No aplica: no es multiagente, se justifica
S2	Gobernanza, trazabilidad y auditoría	3.3 y 9	[pág.]	Citas, registros y revisión trimestral del corpus
S3	Reglas duras, ontologías y grafos	4.1 y 4.2	[pág.]	Reglas duras sí; ontología formal no implementada
S3	Neurosimbólico, grounding y verificación	4.1 y 4.3	[pág.]	Verificador: 0 % de alucinaciones
S3	Razonamiento lógico (proposicional y de primer orden)	4.1	[pág.]	Pendiente: explicar que las reglas son proposicionales y que no se usa lógica de primer orden
S4	Planificación clásica STRIPS y PDDL	5.1	[pág.]	Flujo de seis acciones resuelto por STRIPS
S4	HTN y replanificación	5.2	[pág.]	Replanificación sí; HTN no aplica, el flujo es lineal
S4	LLM como planificador y planificador simbólico	5.3	[pág.]	Pendiente: la comparación no se midió

Sesión	Contenido	Sección	Página	Cómo se aplica o por qué no aplica
S5	Formulación de optimización y problemas NP-duros	6.1	[pág.]	Selección de portafolio como mochila
S5	Metaheurísticas	6.2	[pág.]	Recocido simulado contra óptimo exacto
S5	IA generativa en optimización	6.2	[pág.]	Formular y explicar; FunSearch no se usa, se justifica
S5	Despliegue: Cloud Run, Hugging Face Hub, CI/CD	7	[pág.]	Diseño propuesto; falta un despliegue de prueba
S6	Economía de la IA: CAPEX, OPEX, TCO, equilibrio	8	[pág.]	Tres alternativas, VAN y sensibilidad
S6	Estrategia y modelo de negocio	10.2 y 10.3	[pág.]	Ahorro interno, suscripción y conflicto de interés
S6	Mercado, tendencias y precios de modelos	10.1 y 10.5	[pág.]	Escenario de precios divididos por 10
S6	Riesgos: dependencia y concentración de proveedores	9.2	[pág.]	Matriz con dueño y mitigación
S6	Tokens y activos descentralizados	10.4	[pág.]	No aplica, se justifica
Transversal	Evaluación: métricas, set fijo, juez y piloto	11	[pág.]	Dos conjuntos de preguntas y piloto propuesto

Anexo B. Supuestos del presupuesto

Se adjunta aparte el archivo `Anexo_B_FINAL.xlsx`, con las hojas Supuestos, TCO, Sensibilidad_TCO36, Equilibrio y Escenario_precios_div10. Cada cifra tiene su fuente o la marca de supuesto, y los precios de la API llevan fecha de consulta (2026-11-01).

PENDIENTE: cargar en el Excel los cambios de la sección 8.3 (tokens, horas de GPU, líneas de datos, licencias y cambio organizacional, roles de personal con dedicación y costo mensual), y reemplazar cada supuesto sin fuente por una referencia con fecha. Entregar un solo archivo de Excel.

Anexo C. Declaración de uso de IA

Herramienta	Para qué se usó	Cómo se verificó
Claude (Anthropic)	Desarrollo y revisión del código del proyecto, análisis de los resultados de evaluación, redacción del borrador de este informe y de las preguntas nuevas de evaluación	Pruebas automáticas (56), ejecución local por el grupo, contraste de las cifras con los JSON de evaluación y con `Anexo_B_FINAL.xlsx`
API de OpenAI	Componente evaluado: el modelo del asesor	Mediciones propias de exactitud, costo y latencia
Qwen2.5-1.5B (Hugging Face), en GPU local	Componente evaluado: alternativa de modelo propio	Mediciones propias

PENDIENTE: cada integrante debe agregar las herramientas que usó y confirmar que revisó las cifras y las citas, porque lo que firman es suyo. Declarar que las preguntas nuevas fueron redactadas con ayuda de IA y cuáles revisó una persona externa.

Anexo D. Aportes por integrante

Integrante	Secciones lideradas	Aporte
[Integrante 1]	0, 1 y 12	[completar]
[Integrante 2]	2, 3 y 4	[completar]
[Integrante 3]	5, 6 y 7	[completar]
[Integrante 4]	8, 9, 10 y 11	[completar]

PENDIENTE: reemplazar por los nombres y el aporte real de cada uno. Todos deben poder defender el informe completo.

Lista de verificación antes de entregar

1. **Portada:** nombre de la solución (el asesor), integrantes y fecha.
2. **Formato:** un solo PDF llamado `TAAI2_Tarea_Grupo-N_Apellidos.pdf`, con 20 a 35 páginas sin anexos y letra de 11 pt. Revisarlo con `python -m copilot.engine_taai2 check-pdf`.
3. **Figuras propias pendientes:** la escalera de decisión (1.4), la arquitectura (3.1), el flujo de planificación (5.1), el TCO comparado y la sensibilidad (8), y las métricas de evaluación (11).
4. **Quitar los avisos PENDIENTE** y reemplazarlos por el contenido, o por una justificación si no se puede.
5. **Citar las fuentes** con fecha: precios, leyes y tendencias.
6. **Entregar el Excel** por separado.
7. **Fecha:** la entrega original era el 8 de noviembre a las 23:59; confirmar con el profesor si hay prórroga, porque cada día de atraso descuenta 1,5 puntos.